

PROPUESTA DE PROYECTO DE MACHINE LEARNING

Mundial de Fútbol 2026 – Plataforma Predictiva

Título del Proyecto	GoalPredict 2026: Plataforma de Predicción Deportiva con Machine Learning
Nombre(s) del/los estudiante(s)	Juan Esteban Moreno Gamboa, David Santiago Naranjo Corredor
Asignatura	Electiva Machine Learning Aplicado
Docente	Viviana Alexandra Villanueva Cipagauta
Universidad / Facultad / Programa	UPTC - Facultad Ingenieria - Ingenieria de Sistemas y Computación
Fecha	21/04/2026

1. Título del Proyecto

GoalPredict 2026: Plataforma de Predicción Deportiva con Machine Learning aplicada al Mundial de Fútbol 2026

2. Planteamiento del Problema

El fútbol es el deporte más popular del mundo, con una base de aficionados que supera los 3.5 mil millones de personas. El Mundial de Fútbol FIFA 2026, que se celebrará conjuntamente en Estados Unidos, Canadá y México con un formato ampliado a 48 equipos nacionales, representará el evento deportivo más grande de la historia y generará una demanda sin precedentes de información, estadísticas y análisis deportivos.

En la actualidad, los aficionados al fútbol cuentan con acceso limitado a herramientas que integren datos históricos y modelos predictivos de manera accesible, intuitiva y orientada al usuario promedio. Si bien existen plataformas especializadas para analistas y apostadores profesionales, no existe una solución de consumo masivo que permita a cualquier persona consultar de forma sencilla la probabilidad de victoria de un equipo, tendencias estadísticas históricas y proyecciones para partidos específicos del torneo.

Esta brecha en el mercado representa una oportunidad para desarrollar una aplicación deportiva que utilice técnicas de Machine Learning sobre datos históricos de encuentros internacionales para ofrecer predicciones fundamentadas en evidencia estadística. La plataforma permitirá a los usuarios seleccionar dos selecciones nacionales y obtener, de forma inmediata, la probabilidad de victoria, derrota o empate, así como una serie de estadísticas detalladas para aquellos usuarios que cuenten con una suscripción premium.

La necesidad del proyecto se sustenta en tres pilares fundamentales:

- **Demanda de información deportiva:** El Mundial 2026 ampliará el número de partidos de 64 a 104, incrementando exponencialmente el volumen de confrontaciones y el interés del público.
- **Monetización del contenido deportivo:** El modelo freemium (gratuito/pago) permite capturar tanto al usuario casual como al aficionado que desea información profunda para análisis o apuestas deportivas combinadas.
- **Aplicación práctica del Machine Learning:** El proyecto permite aplicar algoritmos de clasificación y regresión supervisada sobre datos reales, con un caso de uso claro, evaluable y de alto impacto público.

Desde el punto de vista técnico, la predicción de resultados deportivos es un problema complejo de clasificación multiclase (victoria local, empate, victoria visitante) que se ve afectado por múltiples variables: historial de enfrentamientos directos, rendimiento reciente, condición de local o visitante, promedios estadísticos por partido (tarjetas, tiros de esquina, posesión, goles por tiempo), entre otros. La integración de estas variables en un modelo de Machine Learning robusto requiere un diseño cuidadoso del pipeline de datos, desde la adquisición y limpieza del dataset hasta la selección, entrenamiento y evaluación del modelo.

Se propone utilizar como fuente primaria de datos el dataset disponible en Kaggle, en particular las siguientes fuentes:

- **International Football Results (1872–2024)** — Martj42. Kaggle. Más de 47.000 resultados de partidos internacionales con resultado final, equipo local y visitante. Variable objetivo principal para el modelo de clasificación de resultados.
- **European Soccer Database** — Hugomathien. Kaggle. Más de 25.000 partidos con eventos detallados: goles, posesión, tiros de esquina, faltas y tarjetas. Fuente primaria para los modelos de regresión de estadísticas premium.
- **FIFA World Cup 1930–2022** — Piterfm. Kaggle. Datos históricos de todas las ediciones del Mundial con estadísticas completas por partido. Fuente de contexto histórico y features específicas de torneos FIFA.
- **FIFA World Cup 2022 Complete Dataset** — Die9origephit. Kaggle. Información detallada del último Mundial con todas las variables requeridas para los modelos de la capa premium.

3. Pregunta Problema

¿Es posible diseñar y entrenar un sistema de modelos de Machine Learning especializados que, basado en el historial estadístico de enfrentamientos entre selecciones nacionales, permita predecir de forma independiente y complementaria: (1) la probabilidad de victoria, empate o derrota de un equipo mediante un modelo de clasificación multiclase; (2) el volumen esperado de goles totales y por tiempo reglamentario; (3) el número estimado de tarjetas amarillas y rojas por equipo; (4) la cantidad proyectada de faltas y tiros de esquina; y (5) el porcentaje de posesión del balón, con el fin de integrar estas predicciones en una plataforma de información deportiva con modelo de suscripción freemium orientada al Mundial de Fútbol 2026?

4. Objetivo General

Desarrollar una aplicación web de información deportiva con modelo freemium que utilice algoritmos de Machine Learning supervisado para predecir resultados y estadísticas de partidos del Mundial de Fútbol 2026, a partir del análisis de datos históricos de selecciones nacionales disponibles en Kaggle.

5. Objetivos Específicos

1. Identificar, adquirir y preprocesar los datasets de partidos internacionales de fútbol disponibles en Kaggle, garantizando la calidad, completitud y consistencia de los datos para el entrenamiento de los modelos.
2. Realizar un análisis exploratorio de datos (EDA) que permita identificar patrones históricos, distribuciones y correlaciones entre las variables estadísticas de los partidos.
3. Diseñar e implementar un modelo de clasificación supervisado para predecir el resultado de un partido (victoria, empate o derrota) entre dos selecciones, correspondiente a la capa gratuita de la plataforma.
4. Diseñar e implementar modelos de regresión supervisada que estimen variables estadísticas detalladas por partido (tarjetas amarillas, goles por tiempo, tiros de esquina, posesión), correspondientes a la capa premium.
5. Evaluar y comparar el desempeño de los modelos mediante métricas apropiadas (accuracy, F1-score, RMSE) y ajustar los hiperparámetros mediante validación cruzada.
6. Desarrollar una API REST que sirva las predicciones del modelo como servicio de backend para la aplicación.
7. Implementar el frontend de la aplicación con una interfaz intuitiva que permita al usuario seleccionar dos equipos y visualizar los resultados, diferenciando claramente las funcionalidades gratuitas y premium.

6. Metodología Propuesta

Se adoptará la metodología CRISP-DM (Cross-Industry Standard Process for Data Mining), ampliamente utilizada en proyectos de ciencia de datos, adaptada a las necesidades del proyecto:

Fase 1 – Comprensión del Negocio

Definición del alcance del producto, identificación de los dos niveles de servicio (gratuito y premium), y establecimiento de los criterios de éxito del modelo predictivo.

Fase 2 – Comprensión de los Datos

Adquisición de los datasets desde Kaggle. Inspección inicial de variables, detección de valores nulos, duplicados y outliers. Análisis exploratorio con visualizaciones de distribuciones, correlaciones y tendencias históricas.

Fase 3 – Preparación de los Datos

Limpieza del dataset, imputación de valores faltantes, codificación de variables categóricas (equipos, torneos), normalización de variables numéricas, ingeniería de features (promedio móvil de los últimos N partidos, diferencial de goles histórico, porcentaje de victorias en enfrentamientos directos).

Fase 4 – Modelado

Entrenamiento y evaluación de múltiples algoritmos para el modelo de clasificación (Random Forest, XGBoost, Regresión Logística Multinomial) y para los modelos de regresión de estadísticas (Random Forest Regressor, Gradient Boosting). Selección del mejor modelo por validación cruzada k-fold.

Fase 5 – Evaluación

Análisis de métricas: Accuracy, Precision, Recall y F1-Score para clasificación; MAE y RMSE para regresión. Comparación contra un modelo base (baseline) de frecuencia histórica.

Fase 6 – Despliegue

Exposición del modelo como API REST (FastAPI/Flask), integración con frontend web, y configuración del modelo de autenticación para diferenciar usuarios gratuitos y premium.

7. Planteamiento Inicial del Software

Descripción del Producto

GoalPredict 2026 es una aplicación web de información deportiva con modelo freemium que permite a los usuarios consultar predicciones basadas en datos históricos para los partidos del Mundial de Fútbol 2026.

Requerimientos Funcionales – Capa Gratuita

- El usuario podrá seleccionar dos selecciones nacionales participantes del Mundial 2026.
- El sistema mostrará la probabilidad de victoria del equipo A, empate y victoria del equipo B (suma 100%).
- El sistema mostrará el historial de enfrentamientos directos entre ambos equipos (últimos 10 partidos).
- El usuario podrá ver el goleador histórico promedio de cada equipo por partido.
- El sistema estará disponible como aplicación web responsiva.

Requerimientos Funcionales – Capa Premium (Suscripción)

- Todo lo incluido en la capa gratuita.
- Probabilidad de que se anoten goles en el primer tiempo y en el segundo tiempo por separado.
- Promedio esperado de tarjetas amarillas y rojas por equipo en el partido.
- Estimación del número de tiros de esquina por equipo.
- Proyección del porcentaje de posesión del balón por equipo.
- Probabilidad de que el partido tenga más o menos de 2.5 goles totales (Over/Under).
- Panel de combinadas: resumen de predicciones múltiples para apuestas deportivas.
- Exportación del informe de predicción en PDF.

Requerimientos No Funcionales

- Tiempo de respuesta de las predicciones: menor a 3 segundos.
- Disponibilidad del servicio: 99% de uptime durante el torneo.
- Diseño responsivo compatible con dispositivos móviles y de escritorio.
- Seguridad: autenticación JWT para la capa premium.

Variables del Modelo – Tabla de Features

Variable / Feature	Tipo	Capa
Historial de resultados (W/D/L)	Clasificación	Gratuita y Pago
Goles a favor / en contra (promedio)	Numérica	Gratuita y Pago
Rendimiento local vs visitante	Categórica	Gratuita y Pago
Probabilidad de victoria	Probabilística	Gratuita y Pago
Probabilidad de derrota / empate	Probabilística	Gratuita y Pago
Goles en primer tiempo (promedio)	Numérica	Solo Pago
Goles en segundo tiempo (promedio)	Numérica	Solo Pago
Tarjetas amarillas (promedio)	Numérica	Solo Pago
Tarjetas rojas (promedio)	Numérica	Solo Pago
Tiros de esquina (promedio)	Numérica	Solo Pago
Posesión del balón (%)	Porcentual	Solo Pago
Tiros a puerta / fuera (promedio)	Numérica	Solo Pago

8. Técnicas de Machine Learning Propuestas

Aprendizaje Supervisado – Clasificación (Capa Gratuita)

Objetivo: Predecir el resultado de un partido (victoria, empate o derrota) para ofrecer al usuario una estimación clara y rápida de lo que podría ocurrir.

En esta parte del sistema se utilizarán modelos de clasificación, que permiten decidir entre varias opciones posibles. En este caso, el modelo analizará datos históricos de los equipos para estimar cuál tiene más probabilidad de ganar o si el partido terminará en empate.

Se emplearán diferentes enfoques para comparar resultados. Por un lado, modelos como Random Forest y XGBoost, que suelen ser muy precisos al encontrar patrones en los datos. Por otro, un modelo más simple como la regresión logística, que sirve como punto de referencia y permite entender mejor cómo influyen las variables.

Aprendizaje Supervisado – Regresión (Capa Premium)

Objetivo: Estimar estadísticas específicas del partido, como tarjetas, goles por tiempo, tiros de esquina y posesión del balón, para ofrecer un análisis más detallado al usuario.

En esta parte del sistema se utilizarán modelos de regresión, es decir, modelos que permiten predecir valores numéricos en lugar de categorías. La idea es anticipar cómo se comportará un partido en términos de estadísticas, no solo quién ganará.

Se emplearán modelos como Random Forest, que funciona bien cuando los datos tienen comportamientos variados, y Gradient Boosting (como XGBoost o LightGBM), que suele ofrecer muy buena precisión al encontrar patrones en los datos. De forma opcional, también se pueden usar redes neuronales si se cuenta con suficiente información, ya que pueden capturar relaciones más complejas.

Aprendizaje No Supervisado

Objetivo: Agrupar las selecciones nacionales en conjuntos según su estilo de juego y rendimiento histórico, con el fin de enriquecer el análisis del sistema y mejorar la calidad de las predicciones del modelo supervisado.

Se utilizará el algoritmo K-Means para agrupar equipos que se parezcan entre sí en aspectos como goles, posesión del balón, tiros al arco y comportamiento en el juego. Esto permitirá identificar tipos de equipos, por ejemplo, algunos más ofensivos, otros más defensivos o más equilibrados.

9. Arquitectura Propuesta

Capa de Datos

- Fuentes: Datasets de Kaggle (CSV/SQLite) – International Football Results, European Soccer Database, FIFA World Cup Dataset.
- Almacenamiento: Base de datos relacional PostgreSQL para datos históricos procesados.
- Pipeline ETL: Scripts Python (Pandas/NumPy) para limpieza, transformación y carga.

Capa de Modelos (ML Backend)

- Lenguaje: Python 3.10+
- Librerías: Scikit-learn, XGBoost, LightGBM, Pandas, NumPy, Matplotlib/Seaborn.
- Almacenamiento de modelos entrenados: formato .pkl (joblib) o ONNX para portabilidad.

Capa de API

- Framework: FastAPI (Python) – alto rendimiento, documentación automática con Swagger.
- Autenticación: JWT (JSON Web Tokens) para diferenciar usuarios gratuitos y premium.
- Endpoints principales: /predict/result, /predict/stats, /teams, /history.

Capa de Presentación (Frontend)

- Framework: React.js (SPA) o Vue.js.
- Diseño responsivo con Tailwind CSS.
- Visualizaciones interactivas con Chart.js o Recharts.

Infraestructura

- Contenedorización: Docker + Docker Compose.
- Despliegue: Render / Railway / Vercel (opciones gratuitas para prototipo académico).
- Control de versiones: Git + GitHub.

10. Cronograma

Actividad	Semana(s)	Responsable	Entregable / Nota
 DATOS & EDA			
Revisión bibliográfica y selección de datasets (Kaggle)	10	Equipo completo	Definir datasets finales: International Football Results, European Soccer DB, FIFA WC
Limpieza y preprocesamiento de datos	10	Equipo completo	Imputación, deduplicación, normalización, codificación de variables categóricas
Análisis exploratorio de datos (EDA)	10	Equipo completo	Distribuciones, correlaciones, tendencias históricas; visualizaciones con Seaborn/Matplotlib
Ingeniería de features	10	Equipo completo	Promedio móvil N partidos, diferencial goles, % victorias directas, variables lag
 MODELADO – Clasificación (resultado partido)			
Entrenamiento modelo resultado (victoria/empate/derrota)	11	Santiago	Random Forest, XGBoost, Regresión Logística

			Multinomial – validación cruzada k-fold
Evaluación modelo resultado	11	Santiago	Accuracy, Precision, Recall, F1-Score; comparación vs baseline histórico

MODELADO – Regresión (estadísticas premium)

Entrenamiento modelo predicción de goles (1T / 2T / total)	11	Juan	Random Forest Regressor + Gradient Boosting; métricas MAE, RMSE
Entrenamiento modelo predicción de tarjetas (amarillas/rojas)	11	Juan	Modelos independientes por tipo de tarjeta; ajuste de hiperparámetros

Entrenamiento modelo predicción de faltas	12	Santiago	Random Forest Regressor / XGBoost; validación cruzada
Entrenamiento modelo tiros de esquina	12	Juan	Gradient Boosting Regressor; análisis de importancia de features
Entrenamiento modelo posesión del balón (%)	13	Santiago	Incluye posesión diferencial por equipo; métricas RMSE y MAE
Evaluación comparativa de todos los modelos de regresión	13	Juan	Dashboard de métricas unificado; selección de mejores modelos; tuning final

MODELADO – Clustering (agrupación de equipos)

Clustering de selecciones por estilo de juego (K-Means)	13	Santiago	Grupos: ofensivo, defensivo, equilibrado; enriquece features del modelo supervisado
---	----	----------	---

BACKEND & API REST

Diseño de arquitectura del backend y estructura de endpoints	14	Juan	Definir contratos /predict/result, /predict/goals, /predict/cards, /predict/stats, /teams, /history
Implementación API REST (FastAPI)	14	Juan	Serialización de modelos .pkl/ONNX; middleware JWT para capa premium
Configuración de base de datos PostgreSQL y ETL final	14	Juan	Pipeline Pandas → PostgreSQL; scripts de carga histórica
Pruebas unitarias del backend y documentación Swagger	14	Juan	Cobertura mínima 80% endpoints críticos; Swagger auto-generado por FastAPI
 FRONTEND & UI/UX			
Diseño de wireframes y flujos de usuario (free vs premium)	14	Santiago	Diferenciar visualmente capas gratuita y de suscripción; mockups en Figma/Canva
Desarrollo del frontend – capa gratuita (React + Tailwind)	14	Santiago	Selector de equipos, probabilidades resultado, historial directo, goleador promedio
Desarrollo del frontend – capa premium (React + Tailwind)	14	Santiago	Visualizaciones Chart.js/Recharts; Over/Under, panel combinadas, exportación PDF

INTEGRACIÓN, PRUEBAS & CIERRE

Integración frontend ↔ backend ↔ modelos ML	15	Equipo completo	Pruebas end-to-end; verificación de tiempo de respuesta < 3 s
Pruebas funcionales, de carga y ajustes finales	15	Equipo completo	Escenarios reales con datos del Mundial; validar uptime 99%
Documentación técnica (README, arquitectura, decisiones ML)	15	Juan	Diagramas de arquitectura, decisiones de modelo, guía de despliegue Docker
Entrega final y presentación del proyecto	16	Equipo completo	Demo en vivo + informe académico formal

11. Referencias

Hugomathien. (2016). *European Soccer Database* [Conjunto de datos]. Kaggle.
<https://www.kaggle.com/datasets/hugomathien/soccer>

Die9origephit. (2022). *FIFA World Cup 2022 Complete Dataset* [Conjunto de datos]. Kaggle.
<https://www.kaggle.com/datasets/die9origephit/fifa-world-cup-2022-complete-dataset>

Martj42. (2024). *International Football Results from 1872 to 2024* [Conjunto de datos]. Kaggle.
<https://www.kaggle.com/datasets/martj42/international-football-results-from-1872-to-2017>

Piterfm. (2023). *FIFA Football World Cup Dataset (1930–2022)* [Conjunto de datos]. Kaggle.
<https://www.kaggle.com/datasets/piterfm/fifa-football-world-cup>